

第六届中国研究生人工智能创新大赛

BÄLÄBÄLÄ

[多模态假新闻检测系统]

项目文档

[V1.0]

[2024.06.20]

[吧啦吧啦团队]

[自选赛题]

目录

1 项目概况	1
1.1 项目背景	1
1.2 研究现状	2
1.3 应用价值	3
1.4 创新意义	5
1.5 技术可行性分析	5
2 项目规划	6
2.1 计划分工	6
2.2 系统总体设计	7
2.3 技术创新点	8
2.3.1 基于文本信息增强的多模态假新闻检测算法	8
2.3.1 基于大模型正负推理的单模态假新闻检测算法	12
3 实验设置与分析	14
3.1 系统环境	14
3.2 数据集	14
3.3 基于文本信息增强的多模态假新闻检测模型性能对比	15
3.3.1 对比实验	15
3.3.2 消融实验	16
3.4 基于大模型正负推理的单模态假新闻检测模型性能对比	17
3.4.1 大模型生成真实性评估	17
3.4.2 对比实验	18
3.4.3 消融实验	19
4 功能实现	20
4.1 最新事实核查	20
4.2 爬取新闻	21
4.3 大模型分析	21
4.4 新闻预测	22
4.5 其他功能	23
5 总结与展望	25
6 参考资料	26

记录更改历史

[illegible]

1 项目概况

1.1 项目背景

截至 2023 年 12 月,我国网民规模达 10.92 亿人,较 2022 年 12 月增长 2480 万人,互联网普及率达 77.5%¹。网民规模及互联网普及率提升的同时也促进了不同表现形式的网络信息资源在社交平台上飞速产生和传播,并且假新闻的制造与传播没有门槛,这就为假新闻的大肆蔓延提供了肥沃的土壤。假新闻问题不仅扰乱了网络空间秩序,还对现实世界也造成了许多负面影响,甚至引发社会动荡、政治危机和人道主义灾难,2019 年 CHEQ 和巴尔的摩大学的经济研究报道,全球每年因虚假新闻造成的损失高达 780 亿美元^[1]。2024 年 5 月初,胖猫事件引发全网关注,不良媒体通过散播这些假新闻激起群众的同情,以此获取流量、关注,直到官方辟谣,这些虚假新闻才得以遏止,如图 1(a)、图 1(b)、图 1(c)所示。因此,及时有效地检测和阻止假新闻的传播,是维护社会稳定、保障公民权益、提升公众信息素养的重要前提。在信息大爆炸的时代,假新闻的形式又具有多样性、多模态和复杂性,人工进行假新闻辨别的方法往往耗时耗力,所以我们急需采用人工智能的技术实现对假新闻的自动化检测。



图 (a) 虚假新闻



图 (c) 官方公布




图 (b) 警方通报

图 1-1 虚假新闻事件示例

2018 年,国际权威期刊《Science》开设了假新闻专栏,其中《the science of fake news》^[2]提出了假新闻是指形式上模仿新闻媒体内容,在组织和意图上故意编造或歪曲事实,误导或欺骗新闻消费者的虚假信息。并且虚假新闻和真新闻在内容呈现、宣传策略以及情感表达等方面存在显著差异^[3]。例如:真新闻通常基于事实,经过严格的事实

¹ <https://www.199it.com/archives/1682273.html>

核查，内容准确，信息来源可靠，常包含错误或虚假的信息，内容未经证实。真新闻提供详细的背景信息和上下文，内容全面，客观公正。假新闻往往缺乏背景信息，细节模糊，片面且夸大其词。真新闻情感表达相对中立，避免偏向性语言，注重客观报道。具有极端情感的新闻通常都是假新闻，煽动读者情绪以达到自己的目的。除此以外，宣传策略会被恶意媒体用来影响人们的心态^[4]，在互联网时代，虚假新闻的涌现凸显出长期存在的防止虚假新闻的制度壁垒正在受到侵蚀，假新闻具有复杂性、多样性并且数量庞大，解决这样一个全球性的问题需要跨学科的努力，从而建设一个保证新闻真实性的新闻生态系统^[2]。

1.2 研究现状

虚假新闻的自动检测可以看作是一种分类任务，一般包含几个步骤：分析新闻数据的表现形式；构建数学物理模型挖掘新闻的潜在逻辑结构；训练模型并更新模型参数；在新数据上预测新闻真假。传统的假新闻自动检测方法大致分为基于单模态和基于多模态两大类，例如仅仅分析文本或者图像，基于图像的方法利用编辑过的痕迹来验证视觉内容的真实性，例如利用空间域挖掘伪造痕迹，直接在图像像素级别上分析和检测修改与人工痕迹，使用 DCT（离散余弦变换）和相位谱分析来检测假新闻中的图像篡改^[5]涉及将图像从其原始的空间域转换到频率域，这种转换使得分析者能够识别出由图像编辑和合成引起的细微差异。基于文本的方法主要研究新闻情感^[6]、新闻语义^[7]，社交上下文^[8]，宣传策略^[9]等等，随着大模型时代的到来，由于大模型具有丰富的世界知识和强大的推理能力，许多研究者利用大模型的优势来辅助假新闻检测任务^{[10][11]}。

单模态的方法虽然已经取得了令人满意的效果，但实际的新闻内容具有多模态、多样化的特点，单一的模态不足以表达完整的新闻信息，于是多模态的方法越来越受到关注。多模态方法主要集中在两个方面：（1）通过构建实体对齐、关系对齐和语义对齐^[12]。（2）不同的模态特征通过早期融合策略、中期融合策略和晚期融合策略进行融合^[13]。近些年在多模态假新闻检测方面的研究与创新如下：

2019 年 Spotfake 模型^[14]采用直接拼接的方法融合文本特征与图片特征，再进行分类，获得了比采用单一模态检测更好的效果。为后续的多模态融合的假新闻检测提供了一个可用基础框架，如图 1-2 所示，框架分为文本特征提取模块，图片特征提取模块，特征融合模块，分类模块。2021 年 HMCAN 模型^[15]采用 transformer 融合机制捕获图文之间的语义关系，同时提取文本的多层语义用于假新闻检测。2023 年 COOLANT 模型^[11]提出了一个跨模态对比学习机制，旨在实现更准确的图像文本对齐。TRIMOON 模型^[16]使用当下最流行的注意力机制做模态融合，从而获取不同模态之间的关系。2024

年 ARG 模型^[17]融合了大模型的有用推理信息到假新闻检测中，并证明了大模型的判断效果不理想，虽然大模型不是一个好的检测者，但却可以扮演一个很好的建议者为检测提供推理支持。2024 年 FactLLaMA^[18]解释了大模型知识幻觉是因为对知识的学习与训练不够，为了解决大模型知识幻觉的影响，他们添加了文本搜索与反向图片搜索的功能，为大模型分析搜索证据支持。以上模型都体现了在人工智能技术上的创新性，但是在准确度上和模型效率方面还有很大的改进空间，文本的深层语义信息仍然没有充分利用到，不同模态的不一致性现在也还是一个悬而未决的问题。




图 1-2 多模态假新闻检测基础框架

尽管目前先进的方法都表现出了良好的效果，但是都不足以表达新闻的多模态上下文信息和深层语义。虚假新闻的核查绝非易事，既需要对新闻内容微妙感觉的捕捉，也需要一定的背景知识。随着大模型时代的到来，由于大模型拥有渊博的世界知识和强大的推理能力，越来越多的研究者开始探索大模型在不同任务下的可能性^[19]。在这样的背景下，为了缓解社交媒体虚假新闻对个人和社会所造成的负面影响以及弥补已有研究的不足之处，本系统探索了基于信息增强的多模态假新闻检测方法，主要挖掘新闻深层语义，利用大模型推理为假新闻检测做信息补充，由于大模型成本限制，我们还使用知识蒸馏技术设计了蒸馏版本。

1.3 应用价值

为了缓解假新闻造成的负面影响，来自产业界和学术界的专家们积极探索有效治理假新闻的策略，并落实于应用，例如国外的 Logically²，提供基于人工智能技术的虚假信息检测服务，在 2020 年美国总统大选期间为政府和社会媒体提供假新闻检测平台支持。国内的腾讯反谣言中心³，利用大数据分析、自然语言处理等技术对网络上的各类谣言进行辨别，并与权威机构发布真相。一些知名的事实核查网站（FactCheck.org⁴ 和 PolitiFact.com⁵）由专业的团队进行人工事实核查，如图 1-3 所示。由于在线新闻门户和社交媒体网站上的信息呈现爆炸式增长，人工检测方法往往耗时耗力，无法满足线上实时识别的需求，我们急需加强人工智能技术对虚假新闻的自动化检测，为政府

² <https://logically.com/>

³ <https://www.piya.org.cn/>

⁴ <https://www.factcheck.org/>

⁵ <https://www.politifact.com/>

和媒体平台提供支持，保护公众免受虚假信息误导，增强社会信任。然而目前的假新闻检测算法还需要不断更新改进，我们针对已有研究的不足之处，在已有研究的基础上完善多模态假新闻的检测算法模型，并在学术通用的数据集上取得了较高的准确度。根据我们的算法，我们开发了假新闻检测平台，主要关注于新闻内容，实现了对多模态假新闻的自动检测，节省人力，推动了相关技术进步。




图 (a) Logically



图 (b) 中国互联网辟谣平台



图 (c) PolitiFact



图 (d) FactCheck

图 1-3 假新闻辨别网站

该系统的用户可以覆盖到政府、企业和民众个人，政府和公共机构可以利用假新闻检测系统，监测社交媒体和新闻平台上的信息，及时发现和处理假新闻，维护社会稳定和公共安全。社交媒体平台可以利用假新闻检测系统，过滤和标记平台上的假新闻，提升平台内容的质量和用户体验。企业通过引入假新闻检测技术，可以在市场竞争中获得优势，提高市场份额和竞争力，假新闻可能引发法律纠纷，给企业带来法律风险和经济损失。假新闻检测系统可以帮助企业预防和减少这种风险。假新闻的泛滥使得公众对新闻平台的信任度下降。通过引入假新闻检测系统，新闻平台可以有效地提高新闻的准确性和可信度，增强公众对平台的信任度，从而吸引更多的用户和广告客户。

综上所述，假新闻检测系统在新闻平台、企业品牌保护、增值服务、政府应用、社交媒体平台、科学研究与教育、商业竞争和法律风险预防等方面具有重要的商业价值。通过引入和推广假新闻检测技术，可以有效提升信息的真实性和可信度，为各类用户提供可靠的服务和支持。

1.4 创新意义

假新闻检测的核心意义在于其能够有效识别和过滤虚假信息，维护信息生态和公共安全。借助人工智能和大数据分析，假新闻检测能够自动化、实时地识别和过滤虚假信息，显著提高信息处理效率。本文的研究提出了两种算法：（1）基于文本语义增强的多模态假新闻检测模型，结合文本、图像两种模态信息，能够更全面地分析新闻内容，并充分捕获 Bert 的分层语义，从而提高假新闻检测的准确性和鲁棒性；（2）基于大模型正负推理的单模态假新闻检测模型，大模型通过训练海量数据，具备强大的上下文理解和细粒度分析能力，利用大模型为假新闻检测提供的丰富的推理信息，能够使得模型准确识别假新闻的复杂模式和细微差别。在对于成本敏感的场景，我们推出了大模型推理的蒸馏版本。推动了人工智能、自然语言处理和多模态分析等技术在假新闻检测领域的发展与应用，最后根据本文的两种检测模型开发了假新闻检测平台，帮助用户辨别多种模式的新闻的真假，两种算法均取得了比目前先进算法更高的准确度。搭建一个这样的平台并宣传普及新闻检测技术可以减少虚假信息的传播和影响，可以提升公众的媒介素养和信息辨别能力，增强社会整体的信息素养，从而维护社会稳定。

1.5 技术可行性分析

1. 社会可行性。

随着互联网和社交媒体的发展，假新闻在全球范围内迅速传播，导致了严重的社会、经济和政治后果。因此，建立一个有效的假新闻检测系统尤为重要。传统的文本分析方法在应对多模态（文本、图像、视频等）假新闻时显得力不从心，因此多模态假新闻检测系统成为研究的前沿和热点。

2. 数据支持。

训练测试的数据集使用公开可用的假新闻检测数据集，包含有新闻标题正文等文本内容和对应的图片内容。例如 WEIBO^[20]、包含有两种数据集 Politifact 和 Gossipcop 的 FakeNewsNet^[21]等，目前已经有足够的数据来支持假新闻检测的应用系统。

3. 算法模型可行性。

模型环境采用 pytorch 深度学习环境，基于 Transformer 的大型预训练模型 (PLM) 为多模态假新闻检测提供了巨大的机会和潜力^[22]。然而，现有的多模态假新闻检测方法从未利用 PLM 产生的新闻的逐词层级语义。本文提出了一种新颖的多模态假新闻检测方法，通过以下几个方面来实现：（1）设计了一种全局-局部跨注意力机制，以捕捉从 BERT^[23]和 ViT^[24]获取的文本和图像表示之间的相关性；（2）提出了一种嵌入在跨

注意力中的 QK 共享策略，以提高模型效率并确保多模态融合的有效性；（3）从 BERT 中获取逐词层级语义表示，使用 CNN 和 BiLSTM 进行语义增强，以丰富长文本表示的含义。我们还通过与四个最先进的基准方法进行比较，证明了我们方法的有效性和稳定性。

虚假新闻的核查绝非易事，既需要对新闻内容微妙感觉的捕捉，也需要一定的背景知识。随着大模型时代的到来，由于大模型拥有渊博的世界知识和强大的推理能力，越来越多的研究者开始探索大模型在不同任务下的可能性。在虚假信息检测领域，往往存在超出新闻文本本身的隐含上下文，例如作者立场、情感、外部知识等。在这样的背景下，我们使用大模型来生成解释，帮助用户评估新闻的真实性。但大模型推理也受所学知识的影响会产生知识幻觉问题，为了减小大模型知识幻觉的影响，我们设计了推理有用性网络，正确推理作为正样本，错误推理作为负样本训练有用性网络，使得模型可以选择正确的推理为假新闻检测做补充，最后的实验结果证明了我们结果的有效性。并且对于成本敏感的场景我们还设计了知识蒸馏的版本。

4. 计算资源可行性

由于实验使用的是深度学习模型，在训练过程中也需要大量的计算资源，所以我们采用的是 GPU 高性能设备，我们有一台配有两片 3090GPU 的服务器和一台配有一片 3090 的服务器，我们的设备足够运行深度学习模型。具体系统实现中的大模型调用国内大模型 API 生成推理，在基于大模型推理的算法实现中我们使用 Llama3 开源大模型

2 项目规划

2.1 计划分工

项目目标：（1）开发多模态假新闻检测系统，为社会假新闻治理提供我们的方案。（2）在已有研究的基础上，改进最先进的算法，弥补已有研究的不足，以提升检测结果的稳定性。

项目安排：2024.05 基于文本信息增强的多模态假新闻检测算法的实现，成员组队；2024.06-2024.07 成员一负责训练模型，成员二负责前端设计，成员三负责后端接入，互相帮助，协作完成第一版多模态假新闻检测系统。2024.07-2024.08 共同学习，收集资料，确定基于大模型推理辅助的假新闻检测模型，成员一负责模型搭建，训练模型，分析实验结果，撰写项目文档，成员二负责前端优化，做对比实验，成员三负责组织会

议，制作视频，查询资料，共同完成第二版多模态假新闻检测，完善假新闻检测系统。

2.2 系统总体设计

该假新闻检测系统，前端框架构建的交互式用户界面，包括新闻文章的展示、用户输入以及结果的展示。后端采用 Flask 框架，定义应用程序的路由和控制器，根据前端的请求执行相应的操作，包含应用程序的核心业务逻辑，包括假新闻检测的算法、数据处理和分析。系统架构如图 2-1 所示。用户在前端界面输入新闻文章或选择已有文章。前端通过 API 请求将新闻数据发送到后端。后端接收到请求后，通过业务逻辑层处理数据，并调用假新闻分类模型与大模型推理模块进行分析（如框架检测、宣传策略检测），通过 API 响应返回给前端。前端接收到响应后，将分析结果和假新闻辨别结果展示给用户。通过这种架构，系统能够高效地处理和分析新闻文章，实现假新闻检测的功能，并提供用户友好的界面和交互体验。这里的分类模型分为两种（1）基于文本信息增强的多模态假新闻检测模型。（2）基于大模型正负推理的单模态假新闻检测模型。




图 2-1 系统架构图

系统实现的主要功能模块如图 2-2 所示：

（1）最新核查结果展示，给用户一些最新的真假新闻案件的示例，方便用户及时的收到真假新闻辨别信息，和更快了解真假新闻的形式。

（2）新闻内容爬取，输入新闻链接，爬取该链接中新闻的标题、作者、内容、图片等内容，保存到后台。

（3）大模型新闻分析，情感分析用来分析新闻中的偏见、煽动性情感等，宣传策略用来分析新闻的宣传框架，比如移花接木、选择性报道等策略，主题分析用来分析新闻的所属分类是政治类、经济类、军事类、科技类等哪些主题类别，事实逻辑分析是根据已知事实常识对新闻内容进行常识推理。比如是否符合常识、符合逻辑、合理合法。

(4) 文本总结，调用文本摘要生成的网站链接，输入文本内容，快速为用户进行新闻总结。

(5) 反向图片搜索，调用图片搜索网站链接，输入图片，快速为用户获取图片来源，和图片匹配的新闻信息，方便用户用来对比图文信息是否匹配。

(6) 聚合 AI，将多个大模型聚合在一起，提供多模型的灵活选择，适配更多的应用场景，满足用户的各种问题。




图 2-2 系统功能组成

2.3 技术创新点

信息的表现形式经历了从早期的文字到精美图片，再到当前最为流行的短视频的演变。模态的多样性增强了假新闻的迷惑性，使其更易于传播且难以追踪溯源。面对这种情况，如何从多角度评估新闻的真实性，如何更快速、更准确地鉴别假新闻，已成为亟待解决的问题。现今的新闻主要由文字信息和视觉信息构成，虚假新闻检测的研究领域也因此分为文本单模态虚假新闻检测、图片单模态虚假新闻检测和图文多模态虚假新闻检测。文字在新闻中扮演主要角色，提供复杂背景分析和详细事件描述，而图片作为事件发生的证据，直观地传达信息并吸引读者注意。因此，将文本与图片结合起来可以实现信息的互补。然而，现有的方法尚未建立高效通用的多模态融合机制，且未能完全挖掘新闻的完整层次语义信息，这可能会影响假新闻检测的效果。

2.3.1 基于文本信息增强的多模态假新闻检测算法

为了弥补现有研究的不足，我们提出了基于文本信息增强的多模态假新闻检测算法。本算法从提高单模态特征质量从而提高多模态特征的表征能力入手，提出了全局表示与局部表示进行交叉注意力融合的机制，减小融合模块的参数从而减小模型的复杂度。利用卷积操作提取 Bert 隐藏层的语义信息，挖掘文本内容的完整层次语义从而

增强新闻的语义信息。总体模型框架如图 2-3 所示。算法框架主要分为以下 5 个模块。

(1) 数据读取模块，从数据集中获取新闻图片文本对。

(2) 图文编码器，为了精确地获取文本语义和上下文表示，采用预训练语言模型 BERT 提取文本特征。为了适应图片与文本的融合任务并有效地提取图像中的关键特征，采用 ViT 提取图像特征。

(3) 语义增强模块，设计了 Bert CNN 模型，充分利用 BERT 的 12 个隐藏层输出。在卷积操作中，卷积核作为每一层的权重被应用于隐藏层输出，实现了丰富的语义信息地有效提取。在模态融合部分通过跨模态的文本残差连接增强文本主导地位。

(4) 多模态融合网络，采用 QK 共享层策略，通过设置文本和图片模态的 QK 共享层以及 Value 投影层，实现文本和图片的全局和序列表示之间的交叉注意力运算，动态调整全局和局部关注范围，同时降低计算复杂度，提高效率，增强了模型的多模态表达能力。

(5) 分类器。检测器利用具有相应激活函数的全连接层生成预测概率来判断该帖子是否为假新闻，输出分类结果。




图 2-3 基于文本语义增强的多模态检测算法架构

1. 多模态融合机制

该模块旨在融合图像和文本之间的信息，采用 BERT 预训练语言模型编码文本得到文本的序列表示，用[cls]的编码输出来代表文本的全局表示。采用 ViT 预训练语言模型编码图片得到图片的序列表示，用[#]的编码输出来代表图片的全局表示。从文本和图像编码器产生的全局和序列表示用于进行交叉注意力计算，算法的总体架构如图 2-

4 所示。交叉注意力模块采用了一种基于查询矩阵和键矩阵的投影层权重共享策略，其中查询矩阵来自于序列表示的投影，键矩阵来自全局表示的投影。两个不共享的值矩阵投影层分别转换文本序列表示和图片序列表示， W^{TP} 代表文本投影层， W^{IP} 代表图片投影层。在该模块中，一个交叉注意力机制接收来自文本的查询矩阵、值矩阵和来自图片的键矩阵进行注意力计算，得到经图片向量加权的文本表示，另一个交叉注意力机制接收来自图片的查询矩阵、值矩阵和来自文本的键矩阵进行注意力计算，得到经文本向量加权的图片表示。最后将两个交叉注意力的输出拼接作为图片文本的融合输出。设计如图 6 多模态融合模块。下面的方程式说明了计算的过程：

$$K^T = e^T \cdot W^{TP}, e^T \in R^{n \times h_t}, W^{TP} \in R^{h_t \times h} \quad (1)$$

其中 e^T 表示序列表示， W^{TP} 表示文本的 QK 共享线性层。这两个矩阵的乘积 K^T 表示序列 T 的键矩阵。 K^T 的形状为 $R^{n \times h}$ 。

$$q^T = e^{GT} \cdot W^{TP}, e^{GT} \in R^{1 \times h_t} \quad (2)$$

其中 e^{GT} 是通过对 BERT 进行微调得到的全局表示。 q^T 是通过 QK 共享权矩阵 W^{TP} 得到的查询向量，该查询向量将用于检查其与图像序列的相关性。

$$V^T = e^T \cdot W^{TV}, W^{TV} \in R^{h_t \times h} \quad (3)$$

图像的 QK 共享权矩阵与文本的 QK 共享权矩阵设置相似。下面的等式展示了生成图像的查询向量 q^I 、键矩阵 K^I 和值矩阵 V^I 的过程。

$$K^I = e^I \cdot W^{IP}, e^I \in R^{197 \times h_i}, W^{IP} \in R^{h_i \times h} \quad (4)$$

$$q^I = e^{GI} \cdot W^{IP}, e^{GI} \in R^{1 \times h_i} \quad (5)$$

$$V^I = e^I \cdot W^{IV}, W^{IV} \in R^{h_i \times h} \quad (6)$$

其中 K^I ， q^I 的形状分别为 $R^{197 \times h}$ 和 $R^{1 \times h}$ ，，分别与文本的 q^T 和 K^T 的维数兼容。只要获得查询向量和键矩阵，文本和图像之间的 QK 交互就发生在两个所使用的交叉注意块中。等式(7)和等式(8)展示了图像和文本之间的两个交叉注意块中的全局与局部的交互计算的详细细节。

$$h^{TC} = \text{Softmax}\left\{\frac{q^T(K^I)^T}{\sqrt{h}}\right\} \cdot V^T \quad (7)$$

$$h^{IC} = \text{Softmax}\left\{\frac{q^I(K^T)^T}{\sqrt{h}}\right\} \cdot V^I \quad (8)$$

h^{TC} 捕获文本的全局信息与配对图像的序列信息之间的融合信息。 h^{IC} 保留的是图像全局信息和文本序列信息之间的交互信息。最后，拼接作为信息融合的输出。

$$h^{TI} = \text{MLP}(\text{Concat}(h^{TC}, h^{IC})) \quad (9)$$




图 2-4 多模态融合模块算法总体架构

2.语义增强机制

BERT 作为目前最先进的文本编码器，可以提供丰富的语义信息。然而很多研究都忽略了中间的隐藏状态，只采用最后一层的输出，这些隐藏状态也包含着丰富的语义信息。为了挖掘文本的多层语义，本模块捕获了 BERT 的 12 层隐藏信息，并为每一层信息设置一个可学习权重来表示信息的重要程度。最后将加权过的隐藏层信息进行求和作为补充的文本语义信息。由于这个操作类似于卷积操作，所以这个可学习的权重被看作是 1×1 的卷积核，文本语义增强模块可以用公式表示为：

$$Y = \sum_{c=1}^C K^c \otimes H^c, Y \in R^{n \times h_t} \quad (10)$$

$$z = \text{BiLSTM}(Y), z \in R^{1 \times h_t} \quad (11)$$




图 2-5 文本语义增强算法架构

3.分类模块

在分类模块，我们简单的采用经典的分类设计，由一个支持 dropout 的全连接层和 Sigmoid 函数组成。该模块将多模态融合模块、语义增强模块的输出作为输入，从而预

测新闻的真实性，等式(12)展示了计算过程。

$$\hat{y} = \text{Sigmoid}(W_{fc} \cdot (h^{Tl} \oplus z)) \quad (12)$$

最后，将预测值和标签值联合发送到损失函数中进行模型训练。我们采用如下式作为损失函数，如式(13)所示。

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \frac{\lambda}{2n} \sum_w \|w\|^2 \quad (13)$$

2.3.1 基于大模型正负推理的单模态假新闻检测算法

检测假新闻既需要对各种线索的微妙感觉，也需要对现实世界背景的深刻理解，由于大型语言模型经过大量的训练，已经在知识问答^[25]，解释生成^[26]，分析推理^[27]等方面展现出强大的优势，最新的一则研究表明，大语言模型在真假新闻的直接判断上不如小模型，但是利用大模型有效推理，结合大模型推理指导优势与小模型真假判断的优势，取得了很好的效果^[28]。本算法则利用大语言模型的推理优势与小语言模型相结合，设计推理有用性检测模块，使用正负法生成正负推理，作为推理有用性检测模块的训练样本，从而减少大模型知识幻觉的影响。针对成本敏感和要求实时性的场景，我们推出了蒸馏版本，基于大模型正负推理的检测算法总体框架如图 3-6 所示。新闻 C 输入到大模型中得到推理 R ， C 与 R 经过编码器编码输入到推理有用性检测网络中，得到交互加权过的 R' 与 C' 。再将 R' 与 C' 进行特征聚合得到最后的新闻表示 f_{cls} ，最后 f_{cls} 被输入到分类器分类。我们使用蒸馏技术，用 12 层 transformer 学习 f_{cls} ，编码器与分类器的初始化参数都来自于大模型正负推理算法的编码器和分类器参数。为了提高蒸馏性能，蒸馏损失函数使用反向 KL 散度^[29]。




图 2-6 基于大模型正负推理算法框架

1. 正负推理样本生成

我们设计了一种自增强推理校正（ SR^3 ）方法来生成有效的推理，如图 2-7 所示，该方法用于生成有效的正面和负面推理，以增强或削弱新闻的可信度。首先，根据新闻

的标签（例如“虚假”或“真实”）和请求的推理类型（正面或负面），设定可信度分数的变化方向。然后，通过迭代过程，动态调整初始正面或负面的推理和对应的可信度分数。在每次迭代中，根据设定的条件提示新的推理和分数。这个过程持续进行，直到达到预期的可信度增量或达到最大迭代次数为止。最终，算法输出合格的正面和负面推理对。以一篇真新闻 X 为例，我们先假设新闻标签为真，设计问题模板，告诉大模型这是一篇真新闻，使大模型按照真新闻生成符合要求推理，得到的推理 R1 有助于提升检测器的预测性能，则推理 R1 为正推理样本，标签为正确推理，即有用推理。如果我们假设新闻 X 为假，设计问题模板使得大模型按照假新闻生成符合要求的推理，得到的推理 R2 降低检测器预测性能，则推理 R2 为负推理样本，标签为错误推理，即无用推理。我们收集推理的正负样本对，训练推理有用性检测网络，从而减少大模型知识幻觉对检测结果的影响。




图 2-7 SR^3 生成有效推理

2.推理有用性检测网络

由于新闻和推理之间可能存在语义差距，因此有必要将新闻和推理的表示转换为一个共同的特征空间以进行语义规则化。为了实现这一目标，我们进行语义一致性学习，以对齐新闻和推理之间的语义。具体来说，我们提出了三个二分类任务，以预测新闻和推理是否具有语义相关性。给定一则随机选择的新闻及其对应的正面和负面推理，其中正推理样本与新闻的语义相关性为 1，从而表示正推理于新闻真假检测是有用的，而新闻和负面推理之间的相关性设为 0，说明负推理即无用推理与新闻无关，在此基础上，我们进行三个子任务来对齐新闻和推理之间的语义表示。具体实现如图 2-8 所示。




图 2-8 推理有用性检测网络

3 实验设置与分析

3.1 系统环境

系统开发平台

处理器：13th Gen Intel® Core™ i9-13900K × 32

内存：128 GB

硬盘：2.0TB

操作系统：算法训练使用 Ubuntu 64 位操作系统，系统开发使用 Windows64 位操作系统

开发环境：Pytorch2.0 深度学习框架，python3.10 语言，前端 VUE 开发框架，后端 Flask 开发框架

3.2 数据集

对于我们提出的基于文本语义增强的多模态假新闻检测算法架构，我们在学术界广泛使用的三个数据集上验证了我们的算法效果。数据集使用 PolitiFact、Gossipcop、ReCOVery 数据集。里面包括用于训练的数据，还包括验证数据，和测试数据。数据集划分如表 1 所示：

数据集	真新闻		假新闻	
	训练集	测试集	训练集	测试集
PolitiFact	647	75	1117	121
Gossipcop	6253	767	2135	166
ReCOVery	1105	123	194	22

表 3-1 数据集

对于我们提出的基于大模型正负推理的单模态假新闻检测算法架构，数据集使用 PolitiFact、Twitter15、Twitter16 数据集。里面包括用于训练的数据，还包括验证数据，和测试数据。数据集划分如表 3-2 所示：

数据集	真新闻		假新闻	
	训练集	测试集	训练集	测试集
PolitiFact	647	75	1117	121
Twitter15	299	73	253	75
Twitter16	159	48	170	35

表 3-2 数据集

3.3 基于文本信息增强的多模态假新闻检测模型性能对比

我们提出的基于文本语义增强的多模态假新闻检测算法架构，在广泛使用的数据集上比目前最先进的算法高 0.5%~9.2%的准确度和 1.3%~32.4%的 F1 分数。

3.3.1 对比实验

为了突出我们方法的有效性，我们采用了四个知名且具有代表性的现有的多模态假新闻检测模型作为对比，我们根据他们论文中的介绍，通过 [github](#) 收集他们的代码或者复现他们的实验。最后展示的结果显示了我们模型的有效性。

数据集	模型方法	准确度	真新闻			假新闻		
			精确度	召回率	F1	精确度	召回率	F1
PolitiFact	Spotfake	0.796	0.804	0.884	0.843	0.777	0.653	0.711
	Spotfake+	0.842	0.830	0.933	0.879	0.866	0.693	0.770
	HMCAN	0.847	0.902	0.843	0.871	0.772	0.853	0.810
	CAFE	0.882	0.865	0.958	0.909	0.919	0.76	0.832
	ours	0.888	0.896	0.925	0.916	0.873	0.826	0.849

表 3-3 PolitiFact 数据集上的对比效果

数据集	模型方法	准确度	真新闻			假新闻		
			精确度	召回率	F1	精确度	召回率	F1
Gossipcop	Spotfake	0.846	0.848	0.168	0.281	0.846	0.993	0.914
	Spotfake+	0.866	0.669	0.488	0.565	0.895	0.947	0.928
	HMCAN	0.860	0.650	0.469	0.540	0.891	0.945	0.917
	CAFE	0.871	0.819	0.356	0.495	0.875	0.983	0.926
	ours	0.876	0.704	0.531	0.605	0.903	0.951	0.927

表 3-4 Gossipcop 数据集上的对比效果

数据集	模型方法	准确度	真新闻			假新闻		
			精确度	召回率	F1	精确度	召回率	F1
ReCOVery	Spotfake	0.869	0.714	0.227	0.344	0.876	0.983	0.927
	Spotfake+	0.903	0.700	0.636	0.667	0.936	0.951	0.943
	HMCAN	0.924	0.923	0.545	0.687	0.924	0.991	0.957
	CAFE	0.903	0.900	0.409	0.563	0.903	0.991	0.945
	ours	0.937	0.933	0.636	0.756	0.938	0.991	0.964

表 3-5 ReCOVery 数据集上的对比效果

3.3.2 消融实验

系统中采用的文本增强和全局与序列交叉注意力机制多模态融合算法，在相同数据集的情况下，分别去掉文本增强模块、全局与序列交叉注意力融合模块对模型的性能进行评估。

GTA: 系统的算法名称（文本增强和全局与序列交叉注意力机制）

CF-GTA: 该变体表示禁用了模型的基于全局与序列交叉注意力机制的多模态信息融合模块。

SA-GTA: 该变体表示模型的另一版本，其中语义增强功能被关闭。

FA-GTA: 该变体表示关闭了 GTA 模型的信息融合和语义增强两方面效果的 GTA 模型。

使用模型各部分的分类准确度的对比柱状图如下图 3-1 所示，由图可以看出，文本增强模块、全局与序列交叉注意力融合模块设计的优越性。




图 3-1 系统分类准确度对比

图 3-2 展示了三个数据集下，模型预测的 F1 分数，F1 分数越高，说明模型的效果越好，图中显示 GTA 算法的 F1 分数分别在三个数据集下都是最高的，充分说明了模型的优越性。




图 3-2 系统稳定性对比

3.4 基于大模型正负推理的单模态假新闻检测模型性能对比

我们提出的基于大模型正负推理的单模态假新闻检测算法架构，在广泛使用的数据集上比目前最先进的算法高 1.1%~42.9%的准确度。

3.4.1 大模型生成真实性评估

虚假新闻的核查绝非易事，既需要对新闻内容微妙感觉的捕捉，也需要一定的背景知识。随着大模型时代的到来，由于大模型拥有渊博的世界知识和强大的推理能力，越来越多的研究者开始探索大模型在不同任务下的可能性。在这样的背景下，为了弥补已有研究的不足之处，本文探索了基于信息增强的多模态假新闻检测方法，挖掘新闻深层语义，并利用大模型推理为假新闻检测做信息补充。但值得注意的是，这种技术容易产生与事实不符的内容，提供看似合理却不准确的答案。随着《生成式人工智能服务管理暂行办法》的实施，我国生成式人工智能服务领域步入了一个更加规范和有序的发展阶段。在这样的背景下，国内的 8 家备案模型近日成为焦点，其生成内容的事实准确性备受期待。面对这一挑战，上海交通大学清源研究院生成式人工智能研究组（GAIR）做了一系列的评估，探讨了六个模型在事实准确性上的表现⁶：百度的文心一言，抖音的云雀（豆包），百川智能的百川大模型，清华系 AI 公司智谱华章旗下的智谱清言，商汤的商量 SenseChat，以及 MiniMax 的 ABAB 大模型。除了评估的 6 个模型之外，他们以 OpenAI 公司的 GPT-4 作为对照组，与国内的 6 家备案模型在 7 个场景下做评估对比，包含：通用知识场景、科学场景、医药场景、法律场景、金融场景、数学场景、以及中国近代史场景，评估结果如图 3-3 所示。由图可以观察到，在参与评估的 6 家通过备案的国产大模型中，豆包的综合评分最好，不同的模型在不同的角度下的分析结果不一样，各有各的优势。所以我们充分利用每个大模型的优势，综合考虑应用成本与分析效果，选择恰当的大模型为新闻做信息的补充分析说明。

⁶ <https://gair-nlp.github.io/ChineseFactEval/>




图 3-3 不同大模型的答对率评估结果

3.4.2 对比实验

为了突出我们提出的方法的优越性，我们的实验中采用了三种对比方法与我们的蒸馏版本模型进行对比，(1) 在大语言模型（LLM-only）上进行提示，选用的对比大模型为 Llama 3, Gemma 2, Mistral。所有大型语言模型都在链式思维（CoT）和零样本（zero-shot）设置下使用。(2) 在预训练的小语言模型（SLM-only）上进行微调，例如 BERT^[30], RoBERTa^[31], ALBERT^[32]。以及 (3) 任务特定的假新闻检测方法（Task-specific），比如 HSALSTM^[33]、BiGRU^[34]、MUSER^[35]。对比结果如下表所示，T 表示标签为真，F 表示标签为假，P 为精确度，R 表示召回率。

Methods	Acc.	MacF1	P-T	R-T	F1-T	P-F	R-F	F1-F
Llama 3	0.769	0.75	0.727	0.64	0.68	0.79	0.85	0.819
Gemma 2	0.622	0.509	0.518	0.186	0.074	0.642	0.292	0.744
Mistral	0.65	0.627	0.558	0.313	0.535	0.702	0.478	0.59
BERT	0.825	0.814	0.782	0.757	0.726	0.852	0.867	0.859
RoBERTa	0.81	0.794	0.769	0.726	0.726	0.856	0.832	0.844
ALBERT	0.816	0.804	0.769	0.744	0.755	0.844	0.845	0.852
HSALSTM	0.785	0.764	0.767	0.637	0.617	0.848	0.775	0.804
BiGRU	0.74	0.714	0.702	0.592	0.564	0.741	0.736	0.797
MUSER	0.846	0.847	0.835	0.752	0.808	0.866	0.835	0.88
Ours-D	0.857	0.847	0.831	0.792	0.808	0.876	0.897	0.885

表 3-6 PolitiFact 数据集上的对比效果

Methods	Acc.	MacF1	P-T	R-T	F1-T	P-F	R-F	F1-F
Llama 3	0.7085	0.7083	0.7274	0.6567	0.6896	0.6947	0.7601	0.7258
Gemma 2	0.5935	0.5879	0.6138	0.4787	0.5381	0.5821	0.7059	0.6382
Mistral	0.6411	0.6367	0.6723	0.5344	0.5945	0.6221	0.674	0.6776
BERT	0.9179	0.9179	0.9063	0.9308	0.9178	0.9061	0.9064	0.9182
RoBERTa	0.9401	0.9404	0.9305	0.9311	0.9182	0.9308	0.9052	0.9183
ALBERT	0.9173	0.9165	0.9082	0.9263	0.9174	0.9171	0.9035	0.9185
HSALSTM	0.8216	0.8214	0.8794	0.7672	0.7992	0.9121	0.9408	0.9257
BiGRU	0.8894	0.8887	0.8627	0.8086	0.8373	0.917	0.858	0.8969
MUSER	0.9515	0.9516	0.9578	0.945	0.9513	0.9466	0.9466	0.9601
Ours-D	0.9581	0.9592	0.9708	0.9427	0.9568	0.9471	0.9724	0.9599

表 3-7 Twitter15 数据集上的对比效果

Methods	Acc.	MacF1	P-T	R-T	F1-T	P-F	R-F	F1-F
Llama 3	0.771	0.769	0.853	0.729	0.786	0.69	0.828	0.753
Gemma 2	0.542	0.536	0.692	0.375	0.486	0.473	0.771	0.586
Mistral	0.65	0.649	0.743	0.604	0.606	0.568	0.714	0.632
BERT	0.92	0.914	0.955	0.895	0.924	0.926	0.902	0.914
RoBERTa	0.93	0.934	0.949	0.929	0.939	0.928	0.904	0.923
ALBERT	0.906	0.933	0.951	0.933	0.943	0.924	0.923	0.924
HSALSTM	0.903	0.903	0.933	0.933	0.933	0.918	0.943	0.93
BiGRU	0.927	0.926	0.962	0.942	0.951	0.916	0.916	0.916
MUSER	0.938	0.939	0.957	0.937	0.947	0.916	0.942	0.929
Ours-D	0.971	0.97	0.991	0.958	0.974	0.945	0.988	0.966

表 3-8 PolitiFact 数据集上的对比效果

3.4.3 消融实验

为了验证各模块的有效性，我们对我们的模型进行了消融实验，消除三个推理有用性计算模块，并得到每种消融模型的蒸馏版本，具体来说，我们通过禁用 f_{R2T} , f_{T2R} , f_R 的有用性损失计算模块来评估模型各部分的有效性。图 3-4 为蒸馏模型预测性能的结果图，图 3-5 为非蒸馏模型（教师模型）的消融实验特征分布图。




图 3-4 蒸馏模型消融实验的性能对比




图 3-5 教师模型消融实验

4 功能实现

4.1 最新事实核查

功能概述

将最近的核查结果显示在网页开头，以使用户查看和了解最新发生的新闻消息，并了解新闻的真实性，以免公众对最新新闻发生的新闻困惑。

业务规则

滑动展示框，可以查看已经完成的真假新闻示例列表。请参考图 4-1：



图 4-1 最新事实核查展示

4.2 爬取新闻

功能概述

从前端输入新闻的 URL，从而爬取新闻的文本内容和图片内容，将数据打包发送到后端保存，便于后端处理真假检测与新闻分析操作。

业务规则

输入新闻 URL，点击搜索按钮，向后端发送爬取事件的请求，后端接收到请求则执行爬取新闻的操作，实现自动对网页上的内容下载和保存，实现界面请参考下图 4-2：



图 4-2 爬取新闻页面展示

4.3 大模型分析

功能概述

调用国内大模型 API，针对新闻内容展开多角度的分析推理，使用提示学习的范式，具体为大模型设置了 4 个任务模板，将新闻内容和任务描述通过调用大模型 API 的方式发送给大模型，并将大模型分析结果返回给前端展示。具体为新闻分析设置了四个分析任务，情感分析、宣传策略分析、主题分析和事实逻辑分析。

业务规则

点击对应的功能按钮，则可获取相应的分析结果，为用户提供真假新闻的辨别参考信息，实现界面如下：



图 4-3 大模型分析结果展示

4.4 新闻预测

功能概述

点击多模态算法预测调用我们的基于文本信息增强的多模态假新闻检测算法，点击单模态算法预测调用我们的基于大模型正负推理的单模态假新闻检测算法，我们将训练好的模型参数保存为 pt 文件，在对新的新闻进行预测时，调用该 pt 文件中的参数，对新闻进行预测。

业务规则

点击预测结果按钮，触发分类事件，后端接收到分类预测的请求后，调用训练好的模型，将文本和图片编码输入到模型中，进行分类，并将预测结果返回给前端，前端如果收到的是真新闻结果，则用蓝色容器显示预测结果，如果收到的是假新闻结果，则用红色容器显示预测结果。



图 4-4 新闻分类结果

4.5 其他功能

功能概述

为了对文本图像内容有更深刻与准确的把握，我们增加了一些附加的功能模块，比如文本摘要、图像反搜索、聚合 AI 功能等。

业务规则

点击对于的功能模块，即可跳转到相应的功能链接中，获取额外的补充信息，为用户提供全面的信息证据。



图 4-5 其他功能



图 4-6 文本摘要展示




图 4-7 图片反搜索展示




图 4-8 聚合 AI

5 总结与展望

为了弥补已有研究的不足，我们设计了两套算法，基于语义增强的多模态假新闻检测架构利用一个轻量级的交叉注意力机制，减小了模型的参数计算开销，提高了多模态融合的效率 and 性能。此外，我们认为文本内容占新闻的主要部分，对于文本的信息的把握是一个很有挑战性的任务，我们提出了一个文本语义增强模块，挖掘文本的深层语义，充分利用到 BERT 的每一层隐藏层。最后的各项实验结果表明我们的模型的有效性，并且在实际应用中获得了卓越的预测效果。在实验过程中，我们可以看出，大模型在回答诸多问题时会出现一本正经地胡说八道的情况，这种情况有可能会误导用户做出错误的判断。有文献推理分析这种情况可能是由于大模型训练的知识不够，所以研究者们研究了有很多的辅助方法比如 factool 帮助大模型减轻知识幻觉的影响，在本文的研究中，我们利用大模型推理为假新闻检测补充证据，我们设计了推理有用性检测网络，识别大模型的有效推理，从而减小大模型知识幻觉的影响。

虚假新闻的检测绝非易事，在互联网时代，防止虚假新闻的制度壁垒正在受到侵蚀，假新闻的形式多种多样发展迅速，基于视频的假新闻检测问题还有很大的发展空间，解决这样一个全球性的问题需要跨学科和全社会的努力，提高公众的信息素养，从而建设一个保证新闻真实性的新闻生态系统。

6 参考资料

- [1] NGADIRON S, ABD AZIZ A, MOHAMED S S. The spread of COVID-19 fake news on social media and its impact among Malaysians[J]. *International Journal of Law, Government and Communication*, 2021, 6(22): 253-260.
- [2] Lazer DMJ, Baum MA, Benkler Y, et al. The science of fake news[J]. *Science*, 2018, 359(6380): 1094-1096
- [3] Zhou X, Zafarani R. A survey of fake news: Fundamental theories, detection methods, and opportunities[J]. *ACM Computing Surveys (CSUR)*, 2020, 53(5): 1-40.
- [4] Glowacki M, Narayanan V, Maynard S, et al. News and political information consumption in Mexico: Mapping the 2018 Mexican presidential election on Twitter and Facebook[J]. *The Computational Propaganda Project*, 2018.
- [5] Shekar B H, Abraham W, Pilar B. Local DCT-Based Deep Learning Architecture for Image Forgery Detection[M]//*Computer Vision and Machine Intelligence: Proceedings of CVMI 2022*. Singapore: Springer Nature Singapore, 2023: 465-473.
- [6] Zhang X, Cao J, Li X, et al. Mining dual emotion for fake news detection[C]//*Proceedings of the web conference 2021*. 2021: 3465-3476.
- [7] Verma P K, Agrawal P, Amorim I, et al. WELFake: word embedding over linguistic features for fake news detection[J]. *IEEE Transactions on Computational Social Systems*, 2021, 8(4): 881-893.
- [8] Nguyen V H, Sugiyama K, Nakov P, et al. Fang: Leveraging social context for fake news detection using graph representation[C]//*Proceedings of the 29th ACM international conference on information & knowledge management*. 2020: 1165-1174.
- [9] Shu K, Mahudeswaran D, Wang S, et al. Hierarchical propagation networks for fake news detection: Investigation and exploitation[C]//*Proceedings of the international AAAI conference on web and social media*. 2020, 14: 626-637.
- [10] Wan H, Feng S, Tan Z, et al. Dell: Generating reactions and explanations for llm-based misinformation detection[J]. *arxiv preprint arxiv:2402.10426*, 2024.
- [11] Jiang B, Tan Z, Nirmal A, et al. Disinformation detection: An evolving challenge in the age of llms[C]//*Proceedings of the 2024 SIAM International Conference on Data Mining (SDM)*. Society for Industrial and Applied Mathematics, 2024: 427-435.
- [12] Wang L, Zhang C, Xu H, et al. Cross-modal contrastive learning for multimodal fake news detection[C]//*Proceedings of the 31st ACM international conference on multimedia*. 2023: 5696-5704.
- [13] Wu L, Liu P, Zhang Y. See how you read? multi-reading habits fusion reasoning for multi-modal fake news detection[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. 2023, 37(11): 13736-13744.
- [14] Singhal S, Kabra A, Sharma M, et al. Spotfake+: A multimodal framework for fake news detection via transfer learning (student abstract)[C]//*Proceedings of the AAAI conference on artificial intelligence*. 2020, 34(10): 13915-13916.
- [15] Qian S, Wang J, Hu J, et al. Hierarchical multi-modal contextual attention network for fake news detection[C]//*Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval*. 2021: 153-162.
- [16] Xiong S, Zhang G, Batra V, et al. TRIMOON: Two-Round Inconsistency-based Multi-modal fusion Network for fake news detection[J]. *Information fusion*, 2023, 93: 150-158.
- [17] Hu B, Sheng Q, Cao J, et al. Bad actor, good advisor: Exploring the role of large language models in fake news detection[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. 2024, 38(20): 22105-22113.
- [18] Cheung T H, Lam K M. Factllama: Optimizing instruction-following language models with external knowledge for automated fact-checking[C]//*2023 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*. IEEE, 2023: 846-853.
- [19] Wan H, Feng S, Tan Z, et al. Dell: Generating reactions and explanations for llm-based misinformation detection[J]. *arXiv preprint arXiv:2402.10426*, 2024.
- [20] Jin Z, Cao J, Guo H, et al. Multimodal fusion with recurrent neural networks for rumor detection on microblogs[C]//*Proceedings of the 25th ACM international conference on Multimedia*. 2017: 795-816.
- [21] Shu K, Mahudeswaran D, Wang S, et al. Fakenewsnet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media[J]. *Big data*, 2020, 8(3):

171-188.

- [22] Xu P, Zhu X, Clifton D A. Multimodal learning with transformers: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(10): 12113-12132.
- [23] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [24] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [25] Zhang K, Zeng J, Meng F, et al. Tree-of-Reasoning Question Decomposition for Complex Question Answering with Large Language Models[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(17): 19560-19568.
- [26] Bhattacharjee A, Moraffah R, Garland J, et al. Towards llm-guided causal explainability for black-box text classifiers[C]//AAAI 2024 Workshop on Responsible Language Models, Vancouver, BC, Canada. 2024.
- [27] Jin Z, Chen Y, Leeb F, et al. Cladder: A benchmark to assess causal reasoning capabilities of language models[J]. Advances in Neural Information Processing Systems, 2024, 36.
- [28] Hu B, Sheng Q, Cao J, et al. Bad actor, good advisor: Exploring the role of large language models in fake news detection[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(20): 22105-22113.
- [29] Gu Y, Dong L, Wei F, et al. Knowledge distillation of large language models[J]. arXiv preprint arXiv:2306.08543, 2023.
- [30] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arxiv preprint arxiv:1810.04805, 2018.
- [31] Liu Y, Ott M, Goyal N, et al. Roberta: A robustly optimized bert pretraining approach[J]. arxiv preprint arxiv:1907.11692, 2019.
- [32] Lan Z, Chen M, Goodman S, et al. Albert: A lite bert for self-supervised learning of language representations[J]. arxiv preprint arxiv:1909.11942, 2019.
- [33] Guo H, Cao J, Zhang Y, et al. Rumor detection with hierarchical social attention network[C]//Proceedings of the 27th ACM international conference on information and knowledge management. 2018: 943-951.
- [34] Zhang X, Cao J, Li X, et al. Mining dual emotion for fake news detection[C]//Proceedings of the web conference 2021. 2021: 3465-3476.
- [35] Liao H, Peng J, Huang Z, et al. MUSER: A multi-step evidence retrieval enhancement framework for fake news detection[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023: 4461-4472.